引用格式：李晓帅,胡成玺,田子建,等.用于遥感目标检测的轻量化注意力残差增强YOLO架构[J].地球信息科学学报,2026,28(4):1174-1185. [Li X S, Hu C X, Tian Z J, et al. Lightweight attention-residual enhanced YOLO architecture for remote sensing object detection[J]. Journal of Geo-information Science, 2026,28(4):1174-1185.] **DOI:** 10.12082/dqxxkx.2026.250477; **CSTR:** 32074.14.dqxxkx.2026.250477

用于遥感目标检测的轻量化注意力残差增强YOLO架构

李晓帅,胡成玺,田子建*,周　翔,张向阳,李津华
中国矿业大学(北京)人工智能学院,北京 100083

Lightweight Attention-residual Enhanced YOLO Architecture for Remote Sensing Object Detection

LI Xiaoshuai, HU Chengxi, TIAN Zijian*, ZHOU Xiang, ZHANG Xiangyang, LI Jinhua
School of Artificial Intelligence, China University of Mining and Technology (Beijing), Beijing 100083, China

Abstract: [Objectives] Remote sensing target detection is a core technology in geographic information intelligent interpretation. It is of vital importance in fields such as resource exploration, natural disaster assessment, and military target identification. It can provide decision-makers and researchers with quick and accurate surface key information, and plays an important supporting role in implementing policies and making scientific decisions. However, the existing methods are insufficient in lightweighting and real-time performance on edge devices, and the detection accuracy of small targets urgently needs to be improved. **[Methods]** In response to the above issues, this paper proposes a lightweight remote sensing object detection model DSNR-YOLO(Depthwise Separable Convolution with Normalization Attention and Residual Block-YOLO). This model introduces an improved DSNRblock in the backbone part, fusing depth-separable convolution, normalization-based Attention Module (NAM), and residual connection through a dual-branch selection strategy. Maintain detection accuracy while reducing the number of Params(M) and computational complexity; Embed Ghost Convolution (GhostConv) in the feature extraction and fusion stage to further reduce the power consumption of the model; Deploy the Bidirectional Feature Pyramid Network (BiFPN) in the neck network to achieve efficient interaction of multi-scale features and enhance the detection ability of small targets. At the same time, an adaptive weighted mixed loss function is designed to optimize the learning effect of the model on difficult and easy samples. **[Results]** The experiments on the DIOR dataset show that the *mAP* and *mAP*50 of DSNR-YOLO reach 66.9% and 89.0% respectively, with only 18.3 GFLOPs, Params (M) is 7.15, and a frame rate of 128 Frames Per Second (FPS). It improves the detection accuracy while reducing the hardware resource requirements. The detection accuracy is superior to the remote sensing detection models that have emerged in recent years. The comparison results on the SIMD dataset with mainstream

收稿日期：2025-10-14；**修回日期：**2026-01-12.
基金项目：内蒙古自治区重点研发和成果转化计划项目(2025YFHH0001)。 [**Foundation item:** Key Research and Development and Technology Transfer Program Project of Inner Mongolia Autonomous Region, No.2025YFHH0001.]
作者简介：李晓帅(1998—),男,山西运城人,硕士生,主要从事图像处理研究。E-mail: 1036103149@qq.com
***通讯作者：**田子建(1964—),男,湖南长沙人,博士,教授,主要从事矿井监控与通信,矿井目标定位等方面的研究。E-mail: Tianzj0726@126.com

lightweight modules and networks show that under the same deployment conditions, DSNR-YOLO achieves a certain degree of superiority in mAP (2.5%~6.3%) while maintaining a relatively high level of lightweighting, demonstrating the superiority of the overall performance of the model. **[Conclusions]** DSNR-YOLO is a lightweight deep learning model specifically designed for remote sensing target detection scenarios. It integrates the core advantages of lightweight architecture design, real-time inference optimization, and high-precision detection algorithms, achieving a precise balance in three dimensions: model size, running efficiency, and detection performance. This model not only demonstrates significant practical value in actual remote sensing applications, but also has broad promotion and application prospects in emerging fields such as intelligent remote sensing and real-time perception at the edge, providing strong technical support for promoting the development of remote sensing technology towards lightweight, intelligent, and real-time directions.

Key words: object detection; remote sensing image; lightweight; YOLOv11; ghostconv; multi-scale features

***Corresponding author:** TIAN Zijian, E-mail: Tianzj0726@126.com

摘要：【目的】遥感目标检测是地理信息智能解译的核心技术，然而现有方法在边缘设备上的轻量化与实时性不足，且小目标检测精度亟待提升。**【方法】**针对上述问题，本文提出轻量化遥感目标检测模型DSNR-YOLO(Depthwise Separable Convolution with Normalization Attention and Residual block-YOLO)。该模型在主干部分引入改进的DSNRblock，通过双支路选择策略融合深度可分离卷积、基于归一化的注意力模块（Normalization-based Attention Module，NAM）和残差连接，在降低参数量和计算复杂度的同时维持检测精度；在特征提取与融合阶段嵌入幽灵卷积（Ghost Convolution，GhostConv）进一步削减模型功耗；在颈部网络部署双向特征金字塔网络（Bidirectional Feature Pyramid Network，BiFPN）实现多尺度特征高效交互，强化小目标检测能力；同时设计自适应权重混合损失函数，优化模型对难易样本的学习效果。**【结果】**在DIOR数据集上的实验表明，DSNR-YOLO的*mAP*与*mAP*50分别达到66.9%和89.0%，GFLOPs仅18.3，参数量为7.15 M，每秒检测帧率（Frames Per Second,FPS）为128，在提高检测精度的同时减少了硬件资源需求，检测精度优于近年出现的遥感检测模型。SIMD数据集上与主流轻量化模块及网络的对比结果表明，同样部署条件下DSNR-YOLO在保证较高轻量化水平的同时，*mAP*实现不同程度上领先（2.5%~6.3%），展示了模型整体性能的优越性。**【结论】**DSNR-YOLO作为一款面向遥感目标检测场景的轻量化深度学习模型，深度融合了轻量化架构设计、实时推理优化与高精度检测算法的核心优势，在模型体积、运行效率与检测性能三大维度实现了精准平衡。适配资源受限的遥感设备，为实时遥感目标检测提供了高效轻量化方案，具备重要实用价值与广阔应用前景。

关键词：目标检测；遥感图像；轻量化；YOLOv11；幽灵卷积；多尺度特征

1 引言

近年来，遥感技术快速发展，卫星、航空等遥感平台所采集的遥感图像数据的分辨率和覆盖面积不断提高，使得遥感数据成为了获取地球表面信息的主要手段之一。然而，传统深度模型庞大的计算量和参数量，在处理海量数据、适配边缘设备及满足实时性需求时面临严峻挑战。

遥感目标检测的核心任务是从复杂背景的海量影像中识别并定位特定目标（如车辆、船舶、建筑物）。遥感目标检测在资源勘探、自然灾害评估、军事目标识别等领域至关重要，能够为决策者和科研人员快速精准地提供地表关键信息，对实施相关政策和科学决策具有重要的支撑作用。遥感目标检测技术可以用于监测和评估灾害对地表的影响，如洪水、火灾和地震等，从而为灾害救援和灾后重建提供关键信息。

1.1 遥感图像中的轻量化研究

计算机视觉领域已有诸多研究针对遥感图像目标检测的技术难点，开展了深度学习方向的探索并取得显著成果。随着深度学习的部署，虽然大幅提升了精度，但模型的计算密集性与高参数量导致其难以满足遥感应用对处理速度、部署成本（硬件、能耗）和平台适应性（边缘端、嵌入式系统）的严苛要求。轻量化遥感目标检测旨在运用模型剪枝、量化、知识蒸馏及设计轻量级骨干网络等技术手段，在可接受的精度损失范围内，最大限度地压缩模型体积、降低计算复杂度、提升推理速度，最终实现模型在多样化实际场景中的高效、低成本部署与应用。

2021年，Wan等[1]提出了一种新的遥感场景分类方法，该方法结合了轻量级通道注意力和多尺度特征融合判别，实现了先进的检测水平并提供了较好的泛化性能。2022年，Sun等[2]针对现有遥感道路检测网络模型参数大、检测速度慢的问题，提出

了一种轻量级遥感道路检测网络模型，通过特征编码与特征解码阶段的改进，实现了优异的检测性能。Li等[3]提出了一种新型轻量级光学遥感图像中的突出目标检测解决方案，通过减少每个组件的参数和计算量，实现了具有竞争力的性能。2023年，Fan等[4]利用结构剪枝和可分离知识蒸馏两种方法对模型进行轻量级处理，轻量化的同时提高了模型的准确率。2024年，Xu等[5]改进了YOLOv8s网络，并开发了一种轻量级遥感目标检测网络，通过结合多尺度特征融合和上下文信息实现了较低的计算成本和较高的检测准确性。Wang等[6]设计了一个轻量级网络作为骨干网络，该网络可以保持模型精度并保证良好的轻量级。2025年张嘉丹等[7]提出一种基于多尺度高斯上下文特征激励的舰船目标检测方法，通过高斯上下文转换模块以及多尺度特征自适应加权融合方法有效提升了舰船目标检测精度。程塬等[8]梳理双时相高分辨率遥感影像深度学习变化检测典型算法与进展，涵盖多任务，指出未来研究方向与挑战。Fan等[9]提出了一种轻量级网络模型。该模型集成了本地和全局信息处理机制，并引入了快速的正样本分配策略，以适应资源受限的嵌入式和移动平台。Liu等[10]提出了一种用于微小目标检测的专用主干，在保持轻量级的同时实现了有竞争力的检测精度。

尽管上述研究对模型进行了不同程度的改进，并取得了一定的成功，但在平衡检测精度和模型大小方面仍有改进空间。在本文中，引入GhostConv，通过减少冗余特征的提取实现轻量化处理。部署BiFPN双向特征金字塔网络，通过双向特征传播机制促进多尺度特征融合，补偿轻量化带来的精度损失，强化小目标检测性能。最后引入自适应权重的混合损失函数，在保持轻量化水平下实现检测效果提升。

1.2 注意力机制

注意力机制在计算机视觉中的应用已经比较成熟，通过分配权重使神经网络关注输入特征图中的重要特征，可以显著提高目标检测模型的性能。

2020年，Wang等[11]提出了高效通道注意注意机制，该机制使用一维卷积实现局部跨通道交互，避免了在学习通道间依赖关系时压缩和降维操作的影响。2021年，Yang等[12]提出简单无参数注意力模块，可以在不向原始网络添加参数的情况下，为层中的特征映射推断出三维注意力权重，有效地提高了卷积神经网络的表示能力。Liu等[13]针对许多先前的研究专注于通过注意力操作捕获显著特征，但缺乏对权重贡献因素的考虑的问题提出NAM注意力，进一步抑制不重要的通道，通过权重的贡献因素来改进注意力机制，提高模型精度。Misra等[14]于2021年提出三重注意力模块，通过3个分支结构捕捉跨维度交互，同时包含通道信息和空间信息，克服了常见注意力方法中通道和空间分离计算以及未考虑跨维度交互和维度缩减的问题，相比一些传统注意力机制，能更好地表达网络特征。2022年，Xia等[15]提出可变形注意力机制，同时包含了数据依赖的注意力模式，克服了常见注意力方法存在的内存计算成本高、受无关区域影响以及数据不可知等问题。2023年，Lau等[16]，提出大核分离注意力，将深度卷积层的二维卷积核分解为级联的水平和垂直一维核，实现大核注意力相当的性能，并且产生更低的计算复杂度和内存占用。2024年，Si等[17]提出一种空间和通道协同注意模块，表现出即插即用的特性和强大的泛化能力。Sun等[18]面向图像去雾领域提出全连接注意力，通过有效整合全局和局部信息、合理分配权重，使得网络能够更准确地强调有用特征，抑制不太有用的特征。

本文针对性地使用了NAM通道注意力来对深度可分离卷积（Depthwise Separable Convolution，DepSep）进行优化，在保证检测精度的同时，兼顾模型的计算效率和运行速度。

综上所述，遥感目标检测的研究对于提升遥感技术的应用价值、促进相关领域的发展以及应对全球性挑战具有重要的意义。模型轻量化是遥感目标检测模型工程落地的关键手段，其意义体现在多个关键方面：提高运行效率，降低资源消耗，增强模型的可部署性，提升模型的可扩展性。现存核心问题：海量数据带来的计算效率瓶颈；边缘/移动平台（无人机、卫星、手持设备）的硬件资源（算力、内存、功耗）严格受限；实时/近实时处理需求（应急响应、军事等），需求兼顾体积与计算效率的检测方法。为此，本文开展的研究聚焦于轻量化与检测精度的双重收益，通过多模块的协同作用实现模型的轻量化改进。

2 研究方法

本节将展示DSNR-YOLO的整体结构和具体改进。基于遥感目标检测对于参数量，检测效率以

及多尺度融合能力的需求，选择YOLOv11作为基线模型。YOLO（You Only Look Once）[19]是一个著名的物体检测和图像分割模型，为了保证参数量以及功耗满足远端遥感检测设备的需求，本文选取YOLOv11s版本作为基线模型，通过部署改进的特征处理模块，轻量化卷积以及特征融合网络实现针对优化。

2.1 整体结构：

图1是DSNR-YOLO的整体结构图。在主干部分使用改进的DSNRblock，有效降低参数量与计算复杂度的同时保持高检测精度；此外引入幽灵卷积GhostConv进一步削减功耗并在颈部网络部署双向特征金字塔网络BiFPN（图1中红色支路部分）结构实现多尺度特征高效融合，增强小目标检测能力。

2.2 DSNRblock

为了实现轻量化并保证精度水平，本文提出了DSNRblock。DSNRblock（图2）是一个结合了深度可分离卷积（Depthwise Separable Convolution）、NAM（Normalization Attention Module）注意力机制和残差连接的卷积模块。相较于原始的卷积部分，实现了轻量化与检测精度的双重优化。

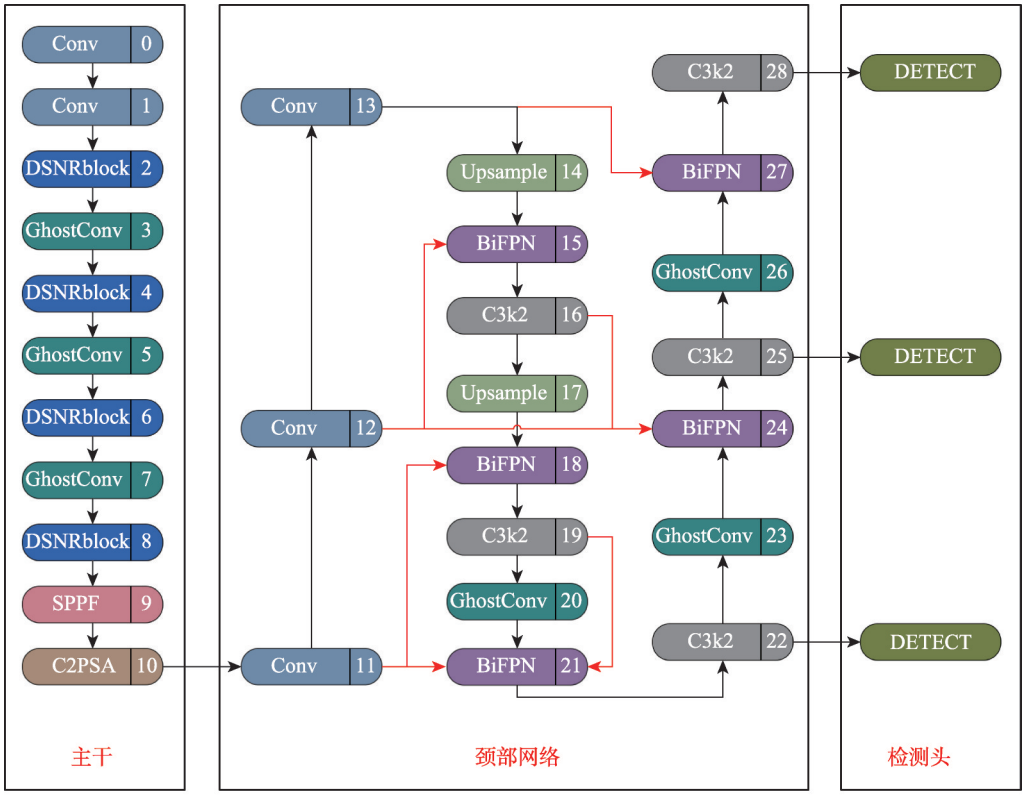
当输入特征图的形状为(B, C_{in}, H, W)，深度卷积的输出特征图的形状为(B, C_{in}, H', W')，其中B：批量大小；C_{in}：输入通道数；H：输入特征图的高度；W：输入特征图的宽度；H'：输出特征图的高度；W'：输出特征图的宽度。

归一化的公式为：

$$\hat{x}_i = \frac{x_i - \mu_B}{\sqrt{\sigma_B^2 + \epsilon}} \tag{1}$$

$$y_i = \gamma \hat{x}_i + \beta \tag{2}$$

式中：$\hat{x}_i$为输入特征图的第i个元素；μ_B为小批量B的均值；σ_B^2为小批量B的方差；ϵ为一个小常数，用于数值稳定；γ和β是可学习的缩放参数和偏移参数；$\hat{x}_i$为归一化后的特征图的第i个元素；y_i为归一化并缩放后的特征图的第i个元素。



注：红色支路表示在颈部网络部署双向特征金字塔网络BiFPN结构实现多尺度特征高效融合。

图1　DSNR-YOLO的整体结构

Fig. 1　Overall structure diagram of DSNR-YOLO

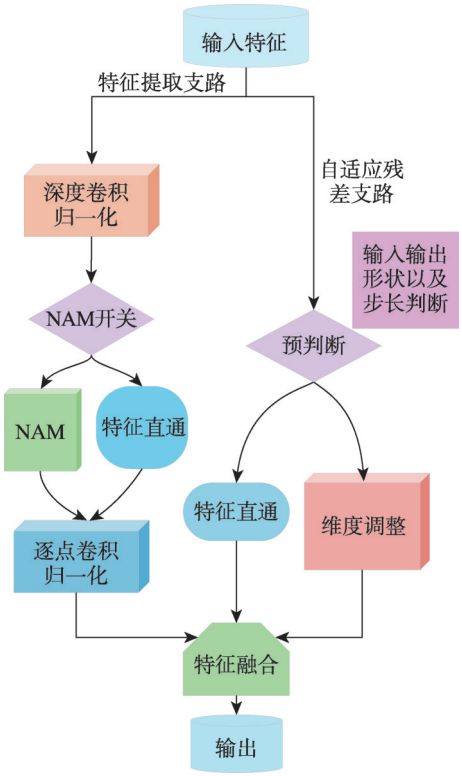


图2 DSNRblock的内部结构

Fig. 2 Internal structure of DSNRblock

NAM的公式见式(3)—式(5)。

$$weight = \frac{|bn.weight|}{\sum_i |bn.weight_i|} \tag{3}$$

$$x_{att} = weight \odot x \tag{4}$$

$$x_{out} = \sigma(x_{att}) \odot x \tag{5}$$

式中：$bn.weight$为归一化的权重；$|\cdot|$为取绝对值；$\odot$为逐元素乘法；$\sigma(\cdot)$为$Sigmoid$激活函数；x_{att}为注意力机制处理后的特征图；x_{out}为最终输出的特征图。

小目标检测存在特征稀疏、易被背景噪声掩盖、有效特征通道占比低的痛点，NAM通过“归一化降噪+通道注意力强化”的协同机制可精准破解。归一化通过均值中心化与方差标准化消除背景噪声引发的全局强度偏移，凸显小目标边缘、纹理等微弱特征；同时NAM会为表征目标关键信息的通道分配高权重，强化小目标的有效特征并抑制无关通道。

残差连接的公式为：

$$x_{out} = x_{conv} + x_{identity} \tag{6}$$

如果输入和输出通道数不同或步幅不为1，则会自动使用1×1卷积调整输入特征图的通道数和尺寸。

$$x_{identity} = \mathrm{Conv}_{1\times1}(x_{input}) \tag{7}$$

式中：x_{conv}为经过卷积操作后的特征图；$x_{identity}$为输入特征图；x_{input}为原始输入特征图；Conv1×1为1×1卷积操作(1×1 convolution operation)。

DSNRblock具备轻量化与高效性，通过深度可分离卷积大幅减少计算量和模型参数，同时保持高特征提取能力，适合资源受限设备运行。其归一化操作稳定训练过程，提升泛化能力，对复杂背景和多变光照条件下的遥感图像尤为重要。NAM模块结合归一化与注意力机制，聚焦重要特征通道，提高特征提取效率与准确性，尤其利于小目标检测。残差连接则确保特征信息在多层网络中的有效传递，减少信息丢失。因此，DSNRblock在YOLO检测网络中用于遥感目标检测时，能显著提升模型的轻量化程度、检测精度和实时性，其有效性将在实验中得到验证。

2.3 GhostConv

为了进一步减小模型体积，减少参数量，本文在DSNR-YOLO的特征提取以及特征融合部分引入了GhostConv[20]。GhostConv(图3)是一种轻量级的卷积神经网络模块，其核心思想是通过引入幽灵模块来减少模型的参数量和计算量。GhostConv通过减少冗余特征的提取，有效降低了模型的参数量和计算复杂度。这使得算法在资源受限的遥感设备上更加适用，同时能够加快模型的推理速度。

2.4 BiFPN结构

为了促进特征融合，增强模型对不同尺度目标的检测精度，本文在DSNR-YOLO的颈部网络部署了BiFPN[21](图4)。BiFPN是一种双向特征金字塔网络，通过构建上、下采样双向路径，实现高低分辨率特征的高效融合，可兼顾不同尺度目标的检测需求，适配遥感图像目标尺度多变的场景。小目标的有效特征集中在浅层网络(高分辨率、低语义)，但浅层特征语义信息弱、易受背景干扰；深层网络(低分辨率、高语义)虽语义强，但小目标特征已被压缩稀释，BiFPN通过双向传播机制，实现深浅层特征的充

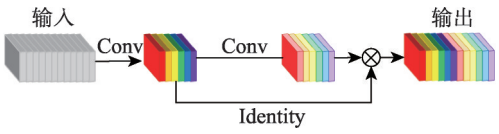


图3 GhostConv的结构

Fig. 3 The structure of GhostConv

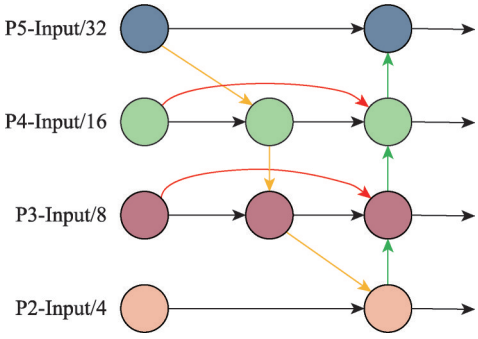


图4　BiFPN的网络结构

Fig. 4　Network structure of BiFPN

分交互。同时，其自适应加权融合机制可规避传统FPN等权融合的缺陷，在背景占比极高的遥感图像中，主动聚焦小目标特征，避免其被背景噪声掩盖。

2.5 损失函数

YOLOv11原有损失函数对所有样本采用等权惩罚机制，无法针对性聚焦关键样本。为了在轻量化条件下提升检测性能，本文设计了一种自适应混合损失函数，它能够自动平衡ATFL[22]损失的难易样本聚焦能力和SLIDE[23]损失的质量分层优化特性。该设计通过可学习权重机制，让模型根据数据特征自主调整损失组合策略——当某个损失组件更有效时自动提升其权重，同时利用正则化约束保持权重平衡，实现了无需人工调参的智能优化。

式(8)为YOLOv11s的基础二元交叉熵损失。

$$loss_bce = -[true \cdot \log\sigma(pred) + (1 - true) \cdot \log(1 - \sigma(pred))] \tag{8}$$

式中：$true$为目标存在性的置信度分数；$\sigma(pred)$为sigmoid概率。

$$SLIDE_loss = loss_bce \times modulating_weight \tag{9}$$

式(9)为SLIDE损失，modulating_weight为IoU感知调制权重，根据目标检测的IoU置信度分层调整权重，优化不同质量样本的学习强度。

$$ATFL_loss = loss_bce \times modulating_factor \tag{10}$$

式(10)为ATFL损失，其中$modulating_factor$为自适应调制因子，根据样本分类难度动态调整权重，让模型更关注难以分类的样本。

$$total_loss = \omega_1 \cdot ATFL_loss + \omega_2 \cdot SLIDE_loss + \alpha + \beta \tag{11}$$

式(11)为混合总损失，其中ω_1和ω_2为2个损失的精度权重；α和β为ATFL和SLIDE的正则化约束，防止损失的权重无限增大。

3　实验设计与结果分析

3.1 实验设计

3.1.1 实验环境

本文实验设置使用了NVIDIA GeForce RTX 2070S GPU，GPU显存容量为8 192 MB。深度学习架构采用Python3.10.16搭配PyTorch2.0.0，基于CUDA11.8进行开发，操作系统为Linux。训练参数方面，设置了批大小为8，训练周期为200次。优化器选择为随机梯度下降，学习率设定为0.01，权重衰减为0.000 5，动量为0.9。

3.1.2 数据集及预处理

卫星图像多车辆数据集(Satellite Imagery Multivehicles Dataset，SIMD)[24]是由巴基斯坦的国家科学技术大学引入的一个中等规模的数据集，包含5 000张RGB卫星图像(分辨率为1 024像素×768像素)，涵盖15个类别，包括车辆(汽车、卡车、公交车)、飞机和船只。该数据集的特点是小尺寸和中等尺寸目标的密集分布，支持车辆检测和实时场景分析等任务。

光学遥感图像数据集(Detection in Optical Remote Sensing Images，DIOR)[25]是一个用于光学遥感图像目标检测的大型数据集。它包含23 463张图像和超过19万个标注实例，涵盖20个目标类别。该数据集在成像条件、季节和目标外观方面表现出显著的多样性，同时目标尺度也存在较大变化。所有图像均为高分辨率，使DIOR适合多尺度检测任务。

由于所选数据集最初未划分为单独的子集，将其按照8∶1∶1的比例划分为训练集、验证集和测试集，以确保模型的泛化能力并防止过拟合。

目标尺度分类有“绝对尺度”和“相对尺度”2种思路，COCO数据集的绝对像素阈值(小目标<32^2像素)不适用于成像分辨率跨度大(1 ~30 m)的遥感图像，易导致小目标界定失真。为此，本文采用“目标-图像相对面积比”分类，依据Chen等[26]的遥感小目标面积分布结论(0.08%~0.58%)，将目标划分为小(≤0.1%)、中(0.1%~0.5%)、大(>0.5%)3类。该5倍梯度阈值相比COCO的9倍像素跨度，更适配遥感小目标尺度集中的特性，可提升实验区分度。表1的结果验证了分类尺度的合理性。

选用SIMD和DIOR数据集可以从数据规模、

表1 分类尺度以及SIMD和DIOR数据集的实例分布情况

Tab. 1 The classification scale and the instance distribution of the SIMD and DIOR datasets

目标类别	相对面积比/%	数据集	
		SIMD	DIOR
小目标	≤0.1	13 942(30.78%)	138 125(71.76%)
中目标	0.1~0.5	18 078(39.90%)	13 830(7.19%)
大目标	>0.5	13 283(29.32%)	40 517(21.05%)

注:括号内为各类型目标数占数据集目标总数的百分比。

类别多样性、目标分布、分辨率等多方面综合评估模型性能,为模型改进和实际应用提供全面反馈,具有重要的研究和应用价值。

3.1.3 评价指标

*mAP*50(%):表示在交并比(Intersection over Union,IoU)阈值为0.5时的*mAP*值。用于初步筛选模型或快速比较不同模型的基本性能。

mAP(%):指*mAP*50-95(%),目标检测中衡量模型性能的核心指标之一,相较于*mAP*50(%),*mAP*50-95(%)更能体现模型的泛化能力。

GFLOPs:表示模型在一次前向传播过程中所需的浮点运算次数。较低的GFLOPs通常意味着模型在硬件上运行时的计算效率更高,适合在资源受限的设备上部署。

Params(M):表示模型中可训练参数的总数。参数越多,模型的表达能力越强,但计算量也越大,可能导致训练和推理速度变慢。

FPS:表示每秒处理的帧数,用于衡量模型在给定硬件上的处理速度。

3.2 消融实验

本文进行了模块的消融实验,展示各模块的部署合理性。在表2的DIOR数据集消融实验中,DSNR-YOLO通过结合DSNRblock、GhostConv和BiFPN以及Loss的四步优化,检测精度提升(*mAP*50+0.6,*mAP*+0.7)的同时减少了参数量(9.43→7.15)以及浮点计算量(21.5→18.3)同时满足了检测设备的FPS需求。

3.3 比较实验

3.3.1 DSNRblock与其他方法对比分析

本文比较了DSNRblock和改进前的DepSep模块部署于YOLOv11s的表现,结果在表3。

DSNRblock在保持较高检测精度的同时,显著减少了计算量和参数量,且在实时性方面表现良好。在资源受限的设备上运行时,DSNRblock是一个很好的选择。附加的视觉测试结果如图5所示。

在图5第1—3行分别为原始图像、YOLOv11s部署DepSep的检测结果和部署DSNRblock后的检测结果。可以看出,使用DepSep改进后的YOLOv11s图像特征捕捉能力较差,无法聚焦物体的精确位置以及属于分类核心的边缘特征。相比之下,本文的算法可精准感知各类目标的特征信息。

为了进一步验证DSNRblock的优势,将它与常见轻量化网络模块改进后的YOLOv11s进行比较,在表4的SIMD测试集上,DSNRblock在保持较高检测精度的同时,显著降低了计算量和参数量,且

表2 DIOR数据集上的消融实验

Tab. 2 Ablation experiments on the DIOR dataset

模型	DSNRblock	GhostConv	BiFPN	Loss	*mAP50*/%	*mAP*/%	*GFLOPs*	*Params*/M	*FPS*
YOLOv11s					88.4	66.2	21.5	9.43	143
1	√				88.4	65.6	18.9	8.00	139
2	√	√			87.8	66.3	16.1	6.69	143
3	√	√	√		88.8	66.8	18.3	7.15	130
DSNR-YOLO	√	√	√	√	89.0	66.9	18.3	7.15	128

注:消融实验中模型1、2、3表示YOLOv11s上搭载不同模块的中间模型。

表3 DIOR数据集上DSNRblock表现

Tab. 3 Performance of DSNRblock on the DIOR dataset

模型	验证集		测试集		指标		
	mAP50/%	*mAP*/%	*mAP*50/%	*mAP*/%	*GFLOPs*	*Params*/M	*FPS*
YOLOv11s	88.2	66.7	88.4	66.2	21.5	9.43	141
DepSep[27]	87.1	65.5	87.7	65.3	18.0	7.96	159
DSNRblock	87.9	66.1	88.4	65.6	18.9	8.00	139

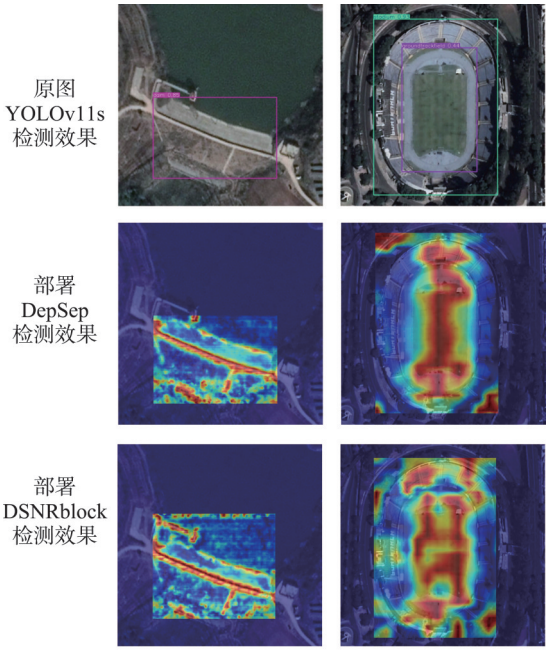


图5　改进算法的感知性能

Fig. 5　Perception performance of the improved algorithm

表4　SIMD测试集上DSNRblock与一些常见轻量化网络变体比较

Tab. 4　Comparison of DSNRblock with common lightweight network variants on the SIMD test set

模型	*mAP*50/%	*mAP*/%	*GFLOPs*	*Params*/M	*FPS*
YOLOv11s	80.2	63.3	21.5	9.43	141
YOLOv11n	78.5	61.8	6.4	2.59	238
PPlcNET[28]	78.8	63.4	18.0	7.96	161
ShuffleNetv2[29]	79.1	62.6	14.9	7.37	182
GhostNetv2[30]	79.3	62.4	15.4	8.37	175
MobileNetV3[31]	70.7	55.5	3.9	5.74	244
DSNRblock	79.6	64.1	18.8	8.00	156

在实时性方面表现良好，这使得它在轻量化和实时性方面具有显著优势，特别是在需要在资源受限的设备上运行时，是理想的选择。

3.3.2　DSNR-YOLO与其他方法对比分析

本节进行了DSNR-YOLO与一些最新的改进成果以及经典轻量化网络（部署于YOLOv11s）进行比较（表5、表6），验证模型性能。

表5　DIOR数据集上DSNR-YOLO与先进检测网络比较

Tab. 5　Comparison of DSNR-YOLO with advanced detection networks on the DIOR dataset

模型	*mAP*50/%	*mAP*/%	*GFLOPs*	*Params*/M	*FPS*	模型大小/MB
YOLO-SSP[32]	87.3	64.7	–	28.3	72	113.2
ProEnDet[33]	–	61.3	–	42.3	32	169.2
FFCA-YOLO[34]	60.1	37.5	–	**7.12**	–	**28.5**
EFR-ACENet[35]	68.3	42.1	–	33.4	–	133.6
YOLOv8s	87.6	65.4	28.6	11.1	**147**	44.4
YOLOv9s	88.9	**67.5**	27.0	7.18	118	28.7
YOLOv10s	87.7	66.0	24.7	8.06	141	32.2
YOLOv11s	88.4	66.2	21.5	9.43	143	37.7
YOLOv12s	88.8	67.2	19.4	9.12	110	36.5
DSNR-YOLO	**89.0**	66.9	**18.3**	7.15	128	28.6

注：加粗数值为最优值。

表6　SIMD验证集上DSNR-YOLO与一些经典轻量化网络比较

Tab. 6　Comparison of DSNR-YOLO on the SIMD validation set with some classic lightweight networks

模型	*mAP*50/%	*mAP*/%	*GFLOPs*	*Params*/M	*FPS*	模型大小/MB
YOLOv11s	82.6	65.5	21.5	9.43	149	37.7
YOLOv11n	78.4	61.4	**6.4**	**2.59**	**185**	**10.4**
Efficientvit[36]	70.8	60.3	13.6	6.30	125	25.2
Vanillanet[37]	77.7	60.8	12.9	5.93	169	23.7
FasterNet[38]	**82.7**	63.2	15.7	7.53	167	30.1
MobileNetV4[39]	78.6	61.6	12.9	7.55	172	30.2
StarNET[40]	78.1	59.4	11.3	5.46	179	21.8
DSNR-YOLO	82.1	**65.7**	18.3	7.15	130	28.6

注：加粗数值为最优值。

表5中，DSNR-YOLO的各个指标比较均衡，实现位居前列的检测精度的同时保证了最佳的GFLOPs以及较好的Params(M)，同时保持不错的FPS以及整体模型大小，综合表现最佳。

在表6的SIMD验证集上，DSNR-YOLO与其他经典轻量化网络进行了比较。DSNR-YOLO在保持较高检测精度的同时，显著降低了计算量和参数量，且在实时性方面表现良好，这使得它在资源受限的设备上运行时，是较为理想的选择。

图6展示了不同模型的*mAP*(%)与帧率(*FPS*)之间的关系。图7是DIOR和SIMD上的检测结果。

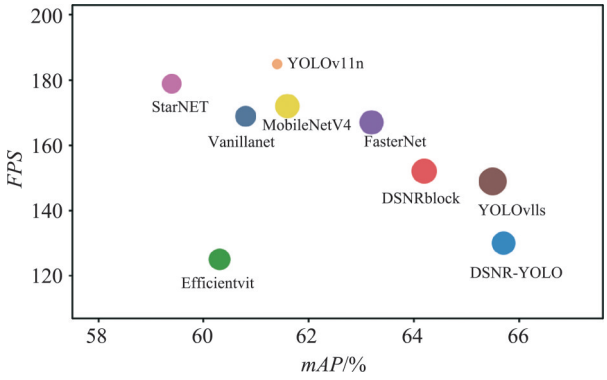
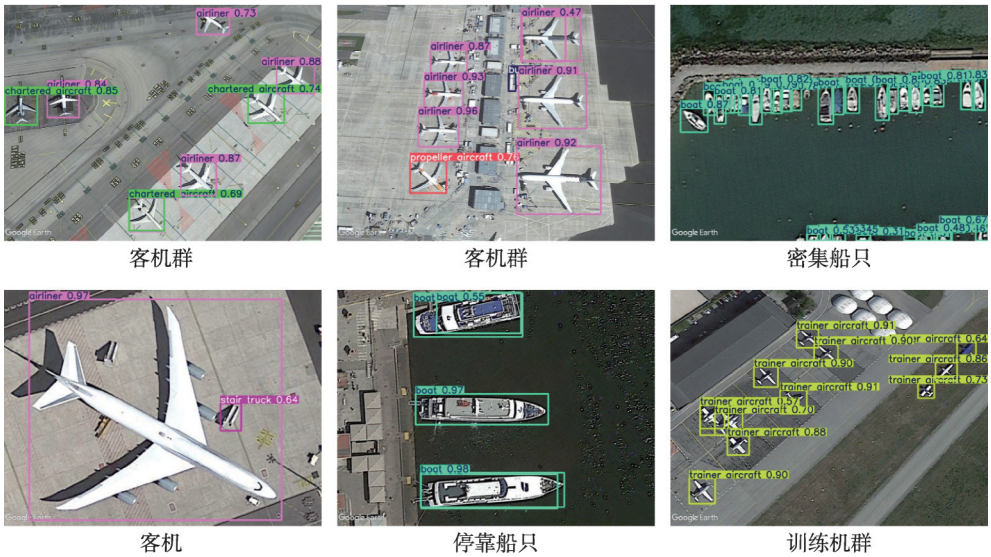


图6 mAP(%) vs FPS参数量为大小

Fig. 6 mAP(%) vs FPS with params as size



(a) DIOR数据集



(b) SIMD数据集

图7 DSNR-YOLO在DIOR和SIMD上的检测结果

Fig. 7 Detection results of DSNR-YOLO on DIOR and SIMD

图6横轴表示模型的平均精度（*mAP*(%)），纵轴表示模型的帧率（FPS）。图像大小反映模型参数量（Params (M)）。DSNRblock和DSNR-YOLO模型不仅在*mAP*(%)上表现良好，而且帧率较高，显示出它们在处理速度和实时性能上的优势。

图7检测结果表明DSNR-YOLO对大目标，密集小目标以及复杂背景下的目标都实现精准检测，证明改进架构的有效性。

4　结论与讨论

4.1　结论

针对遥感目标检测任务中模型计算量大、边缘设备部署难、小目标特征提取不足及多尺度适配性差等核心问题，本文以YOLOv11s为基线模型，提出了融合多模块协同优化的轻量化遥感目标检测模型DSNR-YOLO。在DIOR与SIMD这2个公开遥感数据集上开展系统实验，结果表明：

（1）模型核心DSNRblock特征提取模块，通过双支路选择策略有机融合深度可分离卷积、NAM无参注意力与残差连接，在精简模型参数量的同时强化关键特征捕捉能力。该模块借助归一化降噪与通道注意力强化的协同机制，有效破解小目标特征稀疏、易被背景噪声掩盖的痛点，为轻量化模型保留核心特征提供了新的技术路径。

（2）构建“轻量化-特征融合-损失优化”三位一体的模型改进框架：引入GhostConv幽灵卷积进一步压缩冗余特征，降低模型运行功耗；部署BiFPN双向特征金字塔网络，通过双向特征传播与自适应加权融合机制，实现高低分辨率特征的高效交互，提升多尺度目标检测适应性；设计自适应权重混合损失函数，智能平衡难易样本的学习强度，优化模型泛化性能。该框架为资源受限场景下的遥感目标检测提供了兼具效率与精度的完整解决方案。

（3）模型具备显著的实际应用价值与广泛适用性，可灵活适配无人机、卫星等资源受限的遥感设备。通过在不同数据规模、目标分布及分辨率的SIMD与DIOR数据集上的验证表明，该模型在实现参数量24.2%、浮点计算量14.9%缩减的同时，保证128 FPS的高实时性并且检测精度优于当前主流的StarNET、MobileNet、Vanillanet等轻量化网络，同样环境下检测精度最高领先6.3%（与StarNET比较），最少领先2.5%（与FasterNet比较），这表明模型能够有效应对复杂背景、密集小目标等遥感场景的检测需求，为矿产资源勘探、灾害监测、生态保护等领域的实时遥感解译提供技术支撑。

4.2　讨论

尽管本文提出的DSNR-YOLO模型在轻量化遥感目标检测中表现出较优性能，但仍存在一定改进空间：在目标密集重叠场景中，模型仍存在少量误检与漏检现象；面对云雾、雨雪等恶劣气象条件时，检测鲁棒性有待进一步提升。今后将重点开展3个方面研究：① 优化BiFPN的特征融合策略，设计动态锚框分配机制，提升密集目标场景的检测精度；② 引入自适应去噪模块与DSNRblock融合，增强模型对复杂气象环境的适配能力；③ 探索多模态遥感数据（可见光、红外、SAR）的融合检测方法，同时开展目标种类级、型号级的精细化识别研究，为获取更丰富的地理空间情报提供技术支撑。

AI使用说明： 本文没有使用AI技术。

利益冲突：Conflicts of Interest

所有作者声明不存在利益冲突。

All authors disclose no relevant conflicts of interest.

作者贡献：Author Contributions

李晓帅与胡成玺共同参与本研究的实验设计；李晓帅、胡成玺、周翔协作完成实验数据采集与具体操作；李晓帅、张向阳、李津华负责论文的初稿撰写、内容修改及格式优化；田子建提供研究所需基金支持，并对论文进行最终审查与学术把关。所有作者均阅读并同意最终稿件的提交。

LI Xiaoshuai and HU Chengxi jointly designed the experiment; LI Xiaoshuai, HU Chengxi, and ZHOU Xiang collaborated to complete the experimental data collection and specific operations; LI Xiaoshuai, ZHAN Xiangyang, and LI Jinhua were responsible for the drafting, revision, and format optimization of the manuscript; TIAN Zijian provided financial support for the research and conducted the final review and academic supervision of the manuscript. All authors have read the final version of the paper and agreed to its submission.

参考文献(References)：

[1] Wan H Y, Chen J, Huang Z X, et al. Lightweight channel attention and multiscale feature fusion discrimination for

remote sensing scene classification[J]. IEEE Access, 2021, 9:94586-94600. DOI:10.1109/ACCESS.2021.3093308

[2] Sun S Y, Yang Z, Ma T L. Lightweight remote sensing road detection network[J]. IEEE Geoscience and Remote Sensing Letters, 2022,19:6510805. DOI:10.1109/LGRS.2022.3179400

[3] Li G Y, Liu Z, Bai Z, et al. Lightweight salient object detection in optical remote sensing images via feature correlation[J]. IEEE Transactions on Geoscience and Remote Sensing, 2022,60:5617712. DOI:10.1109/TGRS.2022.3145483

[4] Fan D, Yu S W, Jin F C, et al. Remote sensing urban green space layout and site selection based on lightweight expansion convolutional method[J]. IEEE Access, 2023,11: 99889-99900. DOI:10.1109/ACCESS.2023.3314819

[5] Xu S, Song L, Yin J R, et al. MFFCI-YOLOv8: A lightweight remote sensing object detection network based on multiscale features fusion and context information[J]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2024,17:19743-19755. DOI: 10.1109/JSTARS.2024.3474689

[6] Wang S B, Gao Z M, Jin D H, et al. AMEA-YOLO: A lightweight remote sensing vehicle detection algorithm based on attention mechanism and efficient architecture[J]. The Journal of Supercomputing, 2024,80 (8):11241-11260. DOI:10.1007/s11227-023-05872-2

[7] 张嘉丹,朱坤,张振超,等.基于多尺度高斯上下文特征激励的舰船目标检测方法[J].地球信息科学学报, 2025,27(10):2498-2509. [Zhang J D, Zhu K, Zhang Z C, et al. A method for ship detection based on multi-scale Gaussian contextual feature attention[J]. Journal of Geo-Information Science, 2025, 27(10): 2498-2509.] DOI:10.12082/dqxxkx.2025.240700

[8] 程塨,王光兴,韩军伟.深度学习遥感变化检测综述:典型算法及发展趋势[J].遥感学报,2025,29(6):1587-1597. [Cheng G, Wang G X, Han J W. Deep learning for change detection in remote sensing: A review and new outlooks[J]. National Remote Sensing Bulletin, 2025, 29 (6):1587-1597.] DOI:10.11834/jrs.20254441

[9] Fan F, Zhang M, Liu Y, et al. LRSDet: Lightweight remote sensing target detection network with local-global information awareness and rapid sample assignment[J]. Measurement Science and Technology, 2025, 36(1): 015403. DOI:10.1088/1361-6501/ad82ff

[10] Liu D Y, Zhang J P, Qi Y X, et al. Exploring lightweight structures for tiny object detection in remote sensing images[J]. IEEE Transactions on Geoscience and Remote Sensing, 2025,63:1-15. DOI:10.1109/TGRS.2025.3567345

[11] Wang Q L, Wu B G, Zhu P F, et al. ECA-Net: Efficient channel attention for deep convolutional neural networks [C]//2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Seattle, WA, USA: IEEE, 2020:11531-11539. DOI:10.1109/CVPR42600.2020.01155

[12] Yang L X, Zhang R Y, Li L D, et al. SimAM: A simple, parameter-free attention module for convolutional neural networks[C]//International Conference on Machine Learning. PMLR, 2021,139:11863-11874.

[13] Liu Y C, Shao Z R, Teng Y Y, et al. NAM: Normalization-based attention module[EB/OL]. 2021: arXiv:2111.12419. https://arxiv.org/abs/2111.12419

[14] Misra D, Nalamada T, Arasanipalai A U, et al. Rotate to attend: Convolutional triplet attention module[C]//2021 IEEE Winter Conference on Applications of Computer Vision (WACV). IEEE, 2021:3138-3147. DOI:10.1109/WACV48630.2021.00318

[15] Xia Z F, Pan X R, Song S J, et al. Vision transformer with deformable attention[C]//2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). IEEE, 2022:4794-4803. DOI:10.1109/CVPR52688.2022.00475

[16] Lau K W, Po L M, Rehman Y A U. Large separable kernel attention: Rethinking the large kernel attention design in CNN[J]. Expert Systems with Applications, 2024, 236: 121352. DOI:10.1016/j.eswa.2023.121352

[17] Si Y Z, Xu H Y, Zhu X Z, et al. SCSA: Exploring the synergistic effects between spatial and channel attention[J]. Neurocomputing, 2025, 634: 129866. DOI: 10.1016/j.neucom.2025.129866

[18] Sun H, Wen Y, Feng H J, et al. Unsupervised bidirectional contrastive reconstruction and adaptive fine-grained channel attention networks for image dehazing[J]. Neural Networks, 2024,176:106314. DOI:10.1016/j.neunet.2024.106314

[19] Redmon J, Divvala S, Girshick R, et al. You only look once: Unified, real-time object detection[C]//2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). IEEE, 2016:779-788. DOI:10.1109/CVPR.2016.91

[20] Han K, Wang Y H, Tian Q, et al. GhostNet: More features from cheap operations[C]//2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). IEEE, 2020:1577-1586. DOI:10.1109/CVPR42600.2020.00165

[21] Tan M X, Pang R M, Le Q V. EfficientDet: Scalable and efficient object detection[C]//2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). IEEE, 2020:10778-10787. DOI:10.1109/CVPR42600.2020.01079

[22] Yang B, Zhang X Y, Zhang J, et al. EFLNet: Enhancing fea-

ture learning network for infrared small target detection [J]. IEEE Transactions on Geoscience and Remote Sensing, 2024,62:5906511. DOI:10.1109/TGRS.2024.3365677

[23] Yu Z P, Huang H B, Chen W J, et al. YOLO-FaceV2: A scale and occlusion aware face detector[J]. Pattern Recognition, 2024,155:110714. DOI:10.1016/j.patcog.2024.110714

[24] Haroon M, Shahzad M, Fraz M M. Multisized object detection using spaceborne optical imagery[J]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2020, 13: 3032-3046. DOI: 10.1109/JSTARS.2020.3000317

[25] Li K, Wan G, Cheng G, et al. Object detection in optical remote sensing images: A survey and a new benchmark [J]. ISPRS Journal of Photogrammetry and Remote Sensing, 2020,159:296-307. DOI:10.1016/j.isprsjprs.2019.11.023

[26] Chen C Y, Liu M Y, Tuzel O, et al. R-CNN for small object detection[M]//Computer Vision - ACCV 2016. Cham: Springer International Publishing, 2017: 214-230. DOI: 10.1007/978-3-319-54193-8_14

[27] Chollet F. Xception: Deep learning with depthwise separable convolutions[C]//2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). IEEE, 2017:1800-1807. DOI:10.1109/CVPR.2017.195

[28] Cui C, Gao T Q, Wei S Y, et al. PP-LCNet: A lightweight CPU convolutional neural network[EB/OL]. 2021: arXiv: 2109.15099. https://arxiv.org/abs/2109.15099

[29] Ma N N, Zhang X Y, Zheng H T, et al. ShuffleNet V2: Practical guidelines for efficient CNN architecture design [C]//Computer vision - ECCV 2018. Cham: Springer, 2018: 122-138. DOI:10.1007/978-3-030-01264-9_8

[30] Tang Y H, Han K, Guo J Y, et al. GhostNetV2: Enhance cheap operation with long-range attention [EB/OL]. 2022: arXiv:2211.12905. https://arxiv.org/abs/2211.12905

[31] Howard A, Sandler M, Chen B, et al. Searching for MobileNetV3[C]//2019 IEEE/CVF International Conference on Computer Vision (ICCV). IEEE, 2019: 1314-1324. DOI:10.1109/ICCV.2019.00140

[32] Liu Y L, Yang D G, Song T T, et al. YOLO-SSP: An object detection model based on pyramid spatial attention and improved downsampling strategy for remote sensing images[J]. The Visual Computer, 2025, 41(3): 1467-1484. DOI:10.1007/s00371-024-03434-y

[33] Fan C C, Fang Z R. Probability-enhanced anchor-free detector for remote-sensing object detection[J]. Computers, Materials & Continua, 2024, 79(3): 4925-4943. DOI:10.32604/cmc.2024.049710

[34] Zhang Y, Ye M, Zhu G Y, et al. FFCA-YOLO for small object detection in remote sensing images[J]. IEEE Transactions on Geoscience and Remote Sensing, 2024, 62: 5611215. DOI:10.1109/TGRS.2024.3363057

[35] Ji J Y, Zhao Y F, Li A H, et al. EFR-ACENet: Small object detection for remote sensing images based on explicit feature reconstruction and adaptive context enhancement [J]. Engineering Applications of Artificial Intelligence, 2025,151:110722. DOI:10.1016/j.engappai.2025.110722

[36] Cai H, Li J Y, Hu M Y, et al. EfficientViT: Lightweight multi-scale attention for high-resolution dense prediction[C]// 2023 IEEE/CVF International Conference on Computer Vision (ICCV). IEEE, 2023: 17256-17267. DOI: 10.1109/ICCV51070.2023.01587

[37] Chen H T, Wang Y H, Guo J Y, et al. VanillaNet: The power of minimalism in deep learning[EB/OL]. 2023: arXiv: 2305.12972. https://arxiv.org/abs/2305.12972

[38] Chen J R, Kao S H, He H, et al. Run, don't walk: Chasing higher FLOPS for faster neural networks[C]//2023 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). IEEE, 2023: 12021-12031. DOI: 10.1109/CVPR52729.2023.01157

[39] Qin D F, Leichner C, Delakis M, et al. MobileNetV4: Universal models for the mobile ecosystem[C]//Computer Vision - ECCV 2024. Cham: Springer, 2025: 78-96. DOI: 10.1007/978-3-031-73661-2_5

[40] Ma X, Dai X Y, Bai Y, et al. Rewrite the stars[C]//2024 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). IEEE, 2024:5694-5703. DOI:10.1109/CVPR52733.2024.00544

本文图文责任编辑：蒋树芳 黄光玉